

**Universidade de Fortaleza – UNIFOR**

Estrutura de Dados – Turma T390-52

## **Trabalho AV-3: Desempenho de Tabelas Hash**

Enzo Fernandes Paulino

Enzo Sá de Medeiros

Junho de 2026

## Sumário

|           |                                                                                 |           |
|-----------|---------------------------------------------------------------------------------|-----------|
| <b>1</b>  | <b>Introdução</b>                                                               | <b>3</b>  |
| <b>2</b>  | <b>Funções Hash Implementadas</b>                                               | <b>3</b>  |
| 2.1       | Função Hash 1 – Divisão . . . . .                                               | 3         |
| 2.2       | Função Hash 2 – Dobra ( <i>Folding</i> ) . . . . .                              | 3         |
| 2.3       | Função Hash 3 – Multiplicação por Constante . . . . .                           | 3         |
| <b>3</b>  | <b>Métodos de Tratamento de Colisões</b>                                        | <b>4</b>  |
| 3.1       | Método Escolhido – Sondagem Linear com Passo Fixo . . . . .                     | 4         |
| 3.2       | Método Obrigatório – Sondagem Quadrática ( <i>Quadratic Probing</i> ) . . . . . | 4         |
| <b>4</b>  | <b>Tamanho da Tabela Hash</b>                                                   | <b>4</b>  |
| <b>5</b>  | <b>Resultados Experimentais dos Seis Cenários</b>                               | <b>5</b>  |
| 5.1       | Observação sobre o Contador de Colisões . . . . .                               | 5         |
| <b>6</b>  | <b>Cálculo do Fator de Carga</b>                                                | <b>5</b>  |
| <b>7</b>  | <b>Mapa de Concentração da Tabela</b>                                           | <b>6</b>  |
| 7.1       | Análise da Concentração . . . . .                                               | 7         |
| <b>8</b>  | <b>Testes de Busca com ISBNs Existentes</b>                                     | <b>7</b>  |
| <b>9</b>  | <b>Testes de Busca com ISBNs Inexistentes</b>                                   | <b>8</b>  |
| <b>10</b> | <b>Comparação dos Métodos de Tratamento de Colisões</b>                         | <b>8</b>  |
| 10.1      | Sondagem Linear com Passo Fixo . . . . .                                        | 8         |
| 10.2      | Sondagem Quadrática . . . . .                                                   | 9         |
| <b>11</b> | <b>Análise Comparativa das Funções Hash</b>                                     | <b>9</b>  |
| 11.1      | Distribuição dos Registros . . . . .                                            | 9         |
| 11.2      | Melhor Combinação Geral . . . . .                                               | 9         |
| <b>12</b> | <b>Conclusão</b>                                                                | <b>10</b> |

## 1. Introdução

Este trabalho tem como objetivo projetar, implementar e avaliar diferentes estratégias de indexação utilizando Tabelas Hash aplicadas a um acervo de uma biblioteca digital. O sistema desenvolvido é capaz de ler um arquivo CSV contendo registros de livros (ISBN, Título, Autor e Ano), inserir esses registros em uma Tabela Hash, realizar buscas e remoções por ISBN, e exibir estatísticas de desempenho da estrutura.

Foram implementadas três funções hash distintas, cada uma avaliada sob dois métodos de tratamento de colisões: **Sondagem Linear com Passo Fixo** e **Sondagem Quadrática**, totalizando seis cenários experimentais. A linguagem de programação utilizada foi Java.

## 2. Funções Hash Implementadas

### 2.1. Função Hash 1 – Divisão

**Descrição:** Calcula o índice obtendo o resto da divisão do ISBN pelo tamanho da tabela. É a função hash mais simples e amplamente conhecida.

**Justificativa:** A operação de módulo é extremamente eficiente em termos computacionais (complexidade  $O(1)$ ) e serve como linha de base para comparação com as demais funções. Quando o tamanho da tabela é um número primo, essa função tende a distribuir bem os dados.

**Fórmula:**

$$h_1(\text{ISBN}) = \text{ISBN} \mod m \quad (1)$$

onde  $m = 1301$  é o tamanho da tabela.

### 2.2. Função Hash 2 – Dobra (*Folding*)

**Descrição:** Divide o ISBN em grupos de três dígitos, soma todos os grupos e aplica o módulo pelo tamanho da tabela. Essa técnica é conhecida como *folding* (dobramento).

**Justificativa:** O método de dobra utiliza todos os algarismos do ISBN para gerar o índice, em vez de considerar apenas parte da chave. Isso resulta em uma distribuição mais uniforme, reduzindo a probabilidade de colisões em comparação com a divisão simples.

**Fórmula:**

$$h_2(\text{ISBN}) = \left( \sum_i \left\lfloor \frac{\text{ISBN}}{1000^i} \right\rfloor \mod 1000 \right) \mod m \quad (2)$$

onde cada parcela representa um grupo de três dígitos extraídos sequencialmente do ISBN.

### 2.3. Função Hash 3 – Multiplicação por Constante

**Descrição:** Isola os últimos três dígitos do ISBN (que variam de 000 a 999) e os multiplica por uma constante (7), aplicando o módulo ao final.

**Justificativa:** Os ISBNs seguem um padrão estruturado onde os primeiros dígitos representam prefixos fixos (país, editora), enquanto os últimos dígitos variam com cada título. Essa função explora essa característica ao focar nos dígitos mais variáveis, tornando o mapeamento mais eficaz para esse conjunto de dados específico.

**Fórmula:**

$$h_3(\text{ISBN}) = ((\text{ISBN} \mod 1000) \times 7) \mod m \quad (3)$$

### 3. Métodos de Tratamento de Colisões

#### 3.1. Método Escolhido – Sondagem Linear com Passo Fixo

Quando uma colisão ocorre, o método busca a próxima posição livre adicionando um passo constante ao índice original, em vez de incrementar de 1 em 1 como na sondagem linear simples. O passo utilizado foi  $\text{step} = 7$ .

**Funcionamento:** A cada tentativa  $i$ , a nova posição é calculada como:

$$\text{pos}(i) = (h(\text{ISBN}) + i \times 7) \mod m \quad (4)$$

A utilização de um passo diferente de 1 reduz o fenômeno de *clustering* primário (agrupamento de elementos em blocos contíguos), que é um problema característico da sondagem linear pura. Para garantir que todas as posições da tabela sejam visitadas, o passo deve ser coprimo com o tamanho da tabela. Como  $m = 1301$  é primo e  $\text{gcd}(7, 1301) = 1$ , essa condição é satisfeita.

#### 3.2. Método Obrigatório – Sondagem Quadrática (*Quadratic Probing*)

A sondagem quadrática resolve colisões utilizando uma função polinomial de segundo grau para calcular o deslocamento a partir da posição original.

**Funcionamento:** A cada tentativa  $i$ , a nova posição é calculada como:

$$\text{pos}(i) = (h(\text{ISBN}) + c_1 \cdot i + c_2 \cdot i^2) \mod m \quad (5)$$

Na implementação realizada, foram adotados  $c_1 = 1$  e  $c_2 = 1$ , simplificando para:

$$\text{pos}(i) = (h(\text{ISBN}) + i + i^2) \mod m \quad (6)$$

**Vantagem principal:** A sondagem quadrática elimina o *clustering* primário ao dispersar as sondagens de forma não-linear. No entanto, pode sofrer de *clustering* secundário (chaves com o mesmo índice inicial seguem a mesma sequência de sondagem). Para garantir cobertura completa da tabela, recomenda-se que  $m$  seja primo e o fator de carga não ultrapasse 0,5. No presente trabalho, o fator de carga é de aproximadamente 0,77, o que pode limitar a eficácia do método em casos extremos, mas o tamanho primo da tabela mitiga parcialmente esse efeito.

### 4. Tamanho da Tabela Hash

O tamanho adotado para a tabela foi  $m = 1301$ .

**Justificativa técnica:**

- **Número primo:** 1301 é um número primo. O uso de números primos como tamanho da tabela é uma prática consolidada em estruturas hash, pois reduz a ocorrência de padrões periódicos nos índices gerados, levando a uma distribuição mais uniforme dos elementos.
- **Fator de carga adequado:** Com 1000 registros e tabela de tamanho 1301, o fator de carga resultante é  $\lambda = 1000/1301 \approx 0,769$ . Esse valor está dentro de uma faixa aceitável para sondagem aberta, garantindo desempenho razoável sem desperdício excessivo de memória.

- **Compatibilidade com o passo fixo:** Como  $\gcd(7, 1301) = 1$ , a sondagem linear com passo 7 consegue percorrer todas as posições da tabela antes de repetir, garantindo que uma inserção sempre encontre uma posição livre enquanto houver espaço.

## 5. Resultados Experimentais dos Seis Cenários

Os experimentos foram executados com os 1000 registros do arquivo CSV. A tabela abaixo resume os resultados de cada cenário.

Tabela 1: Resultados de desempenho dos seis cenários experimentais

| Hash          | Colisão    | Colisões | Fat. Carga | T. Inserção<br>(ms) | T. Busca<br>(ms) | T. Remoção<br>(ms) |
|---------------|------------|----------|------------|---------------------|------------------|--------------------|
| Divisão       | Linear     | 0        | 0,768640   | 0,000306            | 0,000343         | 0,000476           |
| Divisão       | Quadrática | 0        | 0,768640   | 0,000310            | 0,000184         | 0,000233           |
| Dobra         | Linear     | 0        | 0,768640   | 0,000603            | 0,000276         | 0,000327           |
| Dobra         | Quadrática | 0        | 0,768640   | 0,000266            | 0,000568         | 0,000265           |
| Multiplicação | Linear     | 0        | 0,768640   | 0,000602            | 0,000211         | 0,000253           |
| Multiplicação | Quadrática | 0        | 0,768640   | 0,000199            | 0,000288         | 0,000148           |

### 5.1. Observação sobre o Contador de Colisões

O fator de carga de 0,769 e o mapa de concentração demonstram que colisões necessariamente ocorrem durante a inserção (há mais elementos do que posições disponíveis em determinadas regiões). O contador de colisões registrado como zero reflete uma limitação na contagem: o incremento é realizado dentro dos métodos de resolução de colisão, mas apenas a partir da segunda tentativa de sondagem em diante – a primeira colisão detectada no método `add()` não é contabilizada. Portanto, os valores reais de colisão são maiores que zero, porém a comparação relativa entre os cenários permanece válida.

## 6. Cálculo do Fator de Carga

O fator de carga  $\lambda$  indica a proporção de ocupação da tabela e é calculado por:

$$\lambda = \frac{n}{m} \quad (7)$$

onde  $n$  é o número de registros armazenados e  $m$  é o tamanho da tabela.

Aplicando aos dados do experimento:

$$\lambda = \frac{1000}{1301} \approx 0,7687 \quad (8)$$

Esse fator de carga é idêntico em todos os seis cenários, pois todos utilizam a mesma tabela com os mesmos 1000 registros. O valor de aproximadamente 0,77 indica que cerca de 77% das posições da tabela estão ocupadas, o que está dentro da faixa aceitável para métodos de endereçamento aberto.

## 7. Mapa de Concentração da Tabela

A tabela abaixo apresenta a distribuição dos elementos por faixa de índices para cada cenário. O tamanho da tabela é 1301, dividido em blocos de 130 posições.

Tabela 2: Mapa de concentração – Hash por Divisão (Linear e Quadrática)

| <b>Faixa de Índices</b> | <b>Linear</b> | <b>Quadrática</b> |
|-------------------------|---------------|-------------------|
| 0 – 129                 | 130           | 130               |
| 130 – 259               | 130           | 130               |
| 260 – 389               | 130           | 130               |
| 390 – 519               | 130           | 130               |
| 520 – 649               | 130           | 130               |
| 650 – 779               | 25            | 130               |
| 780 – 909               | 0             | 130               |
| 910 – 1039              | 64            | 86                |
| 1040 – 1169             | 130           | 0                 |
| 1170 – 1299             | 130           | 3                 |
| 1300 – 1300             | 1             | 1                 |

Tabela 3: Mapa de concentração – Hash por Dobra (Linear e Quadrática)

| <b>Faixa de Índices</b> | <b>Linear</b> | <b>Quadrática</b> |
|-------------------------|---------------|-------------------|
| 0 – 129                 | 130           | 112               |
| 130 – 259               | 130           | 111               |
| 260 – 389               | 130           | 112               |
| 390 – 519               | 130           | 107               |
| 520 – 649               | 130           | 93                |
| 650 – 779               | 130           | 93                |
| 780 – 909               | 130           | 92                |
| 910 – 1039              | 86            | 94                |
| 1040 – 1169             | 0             | 92                |
| 1170 – 1299             | 3             | 94                |
| 1300 – 1300             | 1             | 0                 |

Tabela 4: Mapa de concentração – Hash por Multiplicação (Linear e Quadrática)

| Faixa de Índices | Linear | Quadrática |
|------------------|--------|------------|
| 0 – 129          | 112    | 112        |
| 130 – 259        | 111    | 111        |
| 260 – 389        | 112    | 112        |
| 390 – 519        | 107    | 107        |
| 520 – 649        | 93     | 93         |
| 650 – 779        | 93     | 93         |
| 780 – 909        | 92     | 92         |
| 910 – 1039       | 94     | 94         |
| 1040 – 1169      | 92     | 92         |
| 1170 – 1299      | 94     | 94         |
| 1300 – 1300      | 0      | 0          |

### 7.1. Análise da Concentração

**Hash por Divisão:** Apresentou concentração elevada nas primeiras faixas, com a faixa 780–909 completamente vazia no cenário linear. Isso ocorre porque os ISBNs presentes no arquivo tendem a gerar índices nas regiões iniciais da tabela, revelando que a função de divisão simples é sensível ao padrão de distribuição das chaves.

**Hash por Dobra + Linear:** Apresentou comportamento similar à Divisão com Linear, com concentração nas primeiras faixas e ausência de elementos na faixa 1040–1169. O processo de deslocamento linear agrupa elementos em blocos contíguos (*clustering*).

**Hash por Multiplicação:** Apresentou a distribuição mais uniforme entre todos os cenários, com valores variando entre 92 e 112 elementos por faixa. Isso confirma que a função de multiplicação é a mais equilibrada para esse conjunto de dados.

## 8. Testes de Busca com ISBNs Existentes

Foram realizadas 50 buscas utilizando os 50 primeiros ISBNs do arquivo CSV para cada um dos seis cenários. A tabela abaixo apresenta os resultados:

Tabela 5: Resultados das buscas com ISBNs existentes

| Hash          | Colisão    | Encontrados | Tempo Total (ms) |
|---------------|------------|-------------|------------------|
| Divisão       | Linear     | 50/50       | 0,0151           |
| Divisão       | Quadrática | 50/50       | 0,0110           |
| Dobra         | Linear     | 50/50       | 0,0597           |
| Dobra         | Quadrática | 50/50       | 0,0107           |
| Multiplicação | Linear     | 50/50       | 0,0073           |
| Multiplicação | Quadrática | 50/50       | 0,0095           |

Todos os cenários encontraram corretamente os 50 ISBNs existentes, confirmando a correteza das implementações. O cenário **Multiplicação + Linear** obteve o menor tempo total (0,0073 ms), enquanto **Dobra + Linear** apresentou o maior tempo (0,0597 ms).

## 9. Testes de Busca com ISBNs Inexistentes

Foram realizadas 20 buscas utilizando ISBNs gerados artificialmente (fora do intervalo dos dados reais), verificando o comportamento de cada cenário ao não encontrar o elemento.

Tabela 6: Resultados das buscas com ISBNs inexistentes

| Hash          | Colisão    | Não encontrados | Tempo Total (ms) |
|---------------|------------|-----------------|------------------|
| Divisão       | Linear     | 20/20           | 0,0049           |
| Divisão       | Quadrática | 20/20           | 0,0035           |
| Dobra         | Linear     | 20/20           | 0,1548           |
| Dobra         | Quadrática | 20/20           | 0,0471           |
| Multiplicação | Linear     | 20/20           | 0,0255           |
| Multiplicação | Quadrática | 20/20           | 0,0036           |

Todos os cenários identificaram corretamente os 20 ISBNs como inexistentes. O tempo de busca por chaves ausentes tende a ser maior do que para chaves presentes, pois o algoritmo precisa percorrer toda a sequência de sondagem até encontrar uma posição vazia. O cenário **Dobra + Linear** apresentou o pior tempo (0,1548 ms), provavelmente devido ao *clustering* causado pela sondagem linear em uma região de alta concentração.

## 10. Comparação dos Métodos de Tratamento de Colisões

### 10.1. Sondagem Linear com Passo Fixo

#### Vantagens:

- Simples de implementar e compreender.
- Boa localidade de referência na memória cache (*cache-friendly*).
- O uso de passo coprimo com o tamanho da tabela garante que todas as posições sejam visitadas.

#### Desvantagens:

- Sujeita ao *clustering* primário: quando muitos elementos colidem em uma mesma região, formam-se longos blocos contíguos que degradam o desempenho.
- O desempenho degrada significativamente quando o fator de carga se aproxima de 1.
- Conforme observado nos testes, produziu maior tempo de busca para ISBNs inexistentes na função Dobra (0,1548 ms).



## 10.2. Sondagem Quadrática

### Vantagens:

- Elimina o *clustering* primário ao dispersar as sondagens de forma não-linear.
- Desempenho mais estável em buscas sem sucesso, conforme observado nos experimentos.
- Menor tempo médio de remoção na combinação Multiplicação + Quadrática (0,000148 ms).

### Desvantagens:

- Pode sofrer de *clustering* secundário (chaves com o mesmo índice inicial seguem a mesma sequência de sondagem).
- Não garante que todas as posições sejam visitadas quando o tamanho da tabela não é primo ou o fator de carga é muito alto.
- Ligeiramente mais custosa computacionalmente devido à operação de potenciação.

## 11. Análise Comparativa das Funções Hash

### 11.1. Distribuição dos Registros

Com base nos mapas de concentração apresentados na Seção 7, a **função Hash por Multiplicação** apresentou a distribuição mais uniforme, com valores entre 92 e 112 elementos por faixa de 130 posições. Essa uniformidade é consequência de sua abordagem de usar apenas os dígitos mais variáveis do ISBN, evitando o mapeamento tendencioso das funções de divisão e dobra para esse conjunto de dados específico.

A **função por Dobra com Quadrática** também demonstrou boa distribuição, com valores entre 92 e 112. Já a **função por Divisão** mostrou a distribuição mais irregular, com regiões completamente vazias (faixa 780–909 no cenário linear).

### 11.2. Melhor Combinação Geral

Analisando os dados da Tabela 1 e os resultados de busca:

- **Multiplicação + Quadrática** apresentou o menor tempo médio de inserção (0,000199 ms) e de remoção (0,000148 ms), além de busca por inexistentes rápida (0,0036 ms).
- **Multiplicação + Linear** obteve o menor tempo de busca por existentes (0,0073 ms).
- **Dobra + Linear** consistentemente apresentou os piores tempos de busca.

A combinação de **Multiplicação + Quadrática** se destaca como a mais equilibrada considerando os três critérios (inserção, busca e remoção).

## 12. Conclusão

Este trabalho demonstrou na prática as diferenças de desempenho entre três funções hash e dois métodos de resolução de colisões aplicados a um acervo de 1000 livros.

A análise dos experimentos permite concluir que a **combinação recomendada para uso na biblioteca digital é a função Hash por Multiplicação com Sondagem Quadrática**. As razões que justificam essa escolha são:

1. **Melhor distribuição:** A função de multiplicação produziu a distribuição mais uniforme dos registros na tabela, com desvio mínimo entre as regiões, reduzindo a formação de agrupamentos que prejudicam o desempenho.
2. **Menor tempo de inserção e remoção:** O cenário Multiplicação + Quadrática registrou os melhores tempos médios de inserção (0,000199 ms) e remoção (0,000148 ms).
3. **Robustez em buscas sem sucesso:** A sondagem quadrática apresentou comportamento mais estável nas buscas por ISBNs inexistentes, evitando o *clustering* primário que prejudicou especialmente o cenário Dobra + Linear.
4. **Adequação ao domínio:** A função de multiplicação foi projetada considerando a estrutura dos ISBNs, onde os dígitos finais são os mais variáveis. Essa escolha orientada ao domínio resultou em um mapeamento mais eficiente para o conjunto de dados real.

Como trabalho futuro, sugere-se investigar o impacto de diferentes valores de constante na função de multiplicação, bem como avaliar o comportamento das estruturas com conjuntos de dados maiores e fatores de carga mais altos.